TiDB 的 HTAP 之路

过去，现在和将来

PingCAP TiDB

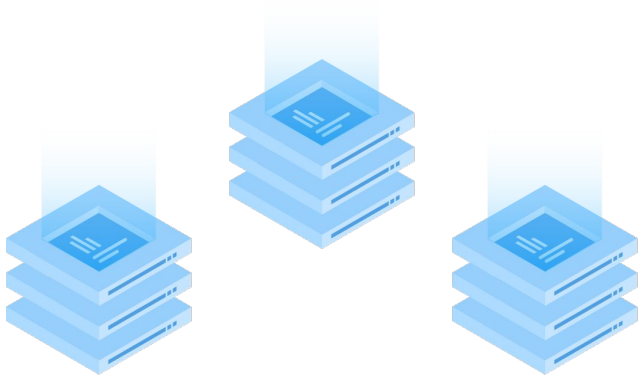

About Me

- 马晓宇
- 分析产品负责人@PingCAP
- 曾就职于网易杭研，担任 BigData Infra Team Lead
- 主要关注大数据，分布式数据库，SQL on Hadoop 等领域

TiDB 有很多故事

- 每个故事都可以有多个视角
- 这是一个从 AP 视角讲 HTAP 故事的分享，当然还有技术讨论

TiDB for HTAP

100% TP 和 80% AP

很久以前，这曾经是我们的 Slogan

PingCAP TiDB

TiDB for HTAP

100% TP 和 80% AP

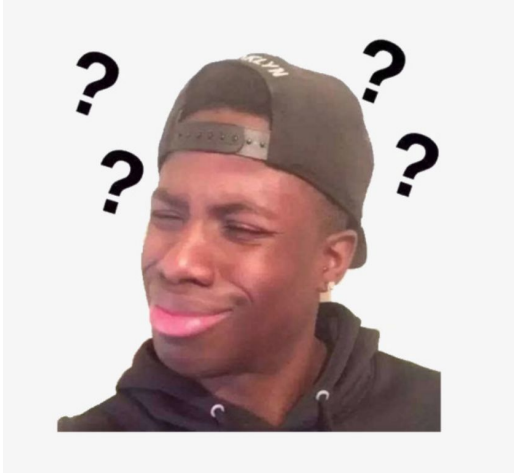

用户:为什么是 80% 不是 75%，也不是 85% ？

TiDB for HTAP

TiDB 是一款 *HTAP* 数据库

所以，后来我们改用比较精确（时髦）的说法...

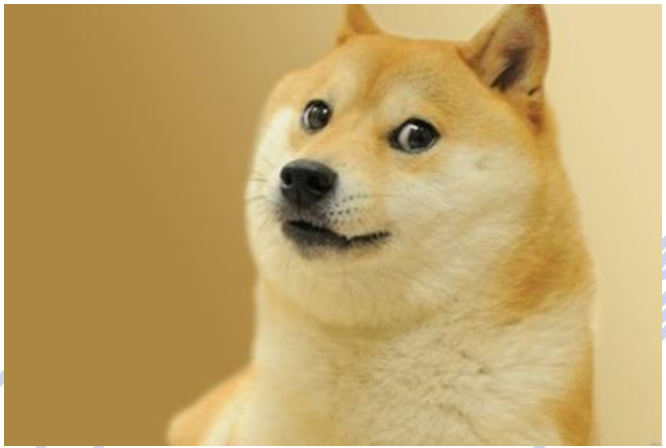

PingCAP TiDB


TiDB for HTAP
It's a long long journey

从 TiDB 的上古时代说起

- 受到 Google Spanner 启发，我们做了 TiDB
- 在 Pre GA 版本，TiDB 是
  - 一个可自由扩容（算力，存储）的数据库
  - 兼容支持 MySQL 语法和协议
  - 透明的数据分片策略 - Range 分片
  - 强一致，无视分片的分布式事务支持

TiDB 架构 - 原始

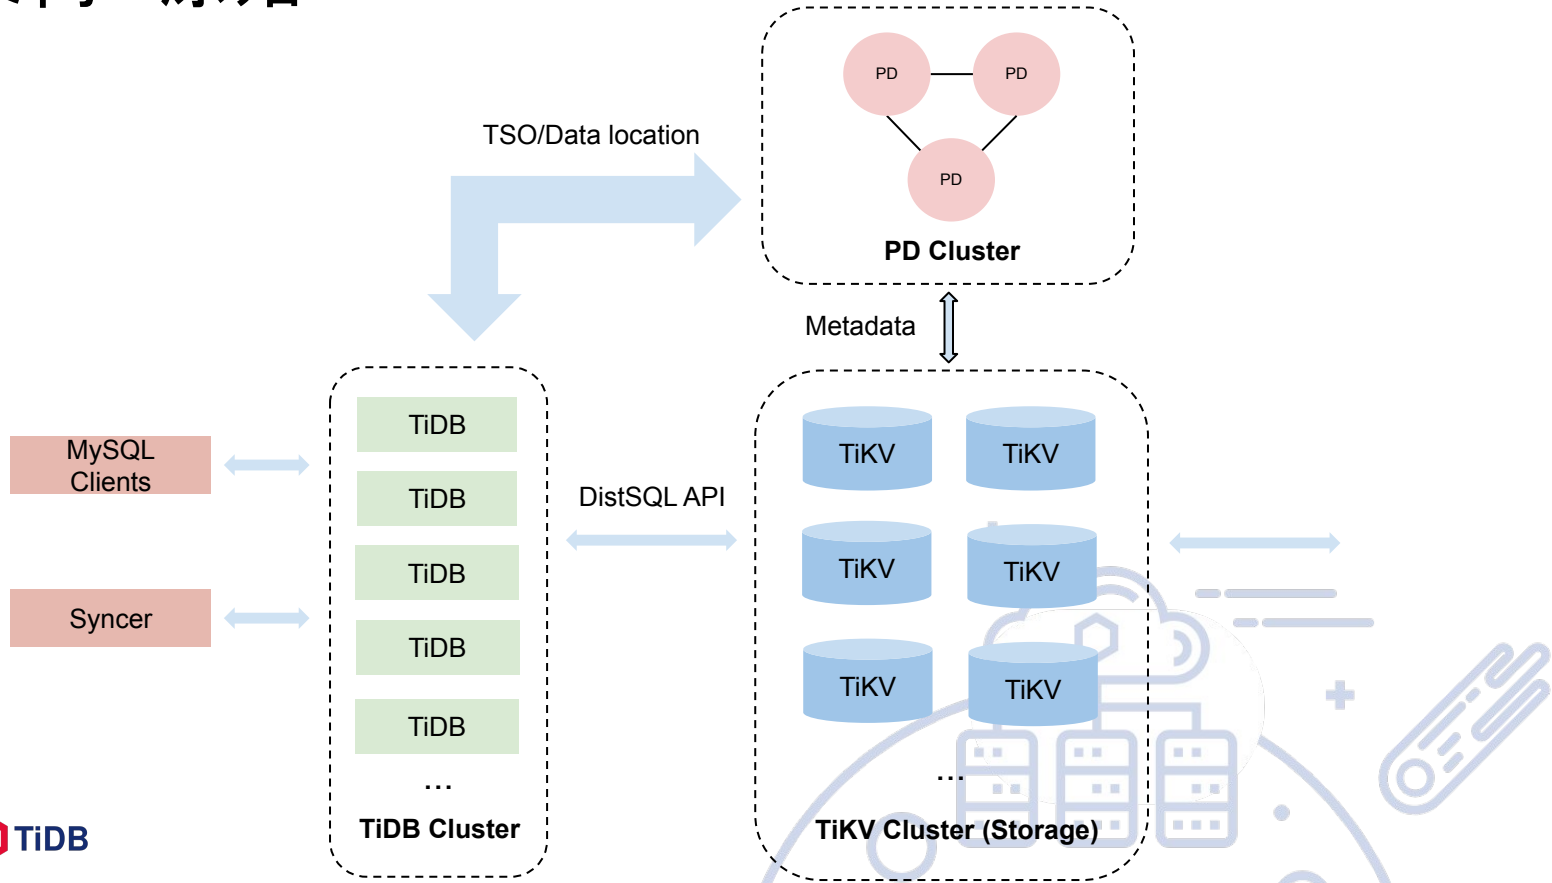

PingCAP TiDB

简单说:同款不同尺寸

S

XXXXXXXXXXXL

TP 处女秀

- 我们：TiDB 很好用的啦，可以替换分库分表 MySQL 做 TP 业务。
- 客户：我咋知道你们够稳定呢？我们先把生产库同步到 TiDB 集群测测看吧。

TP 处女秀

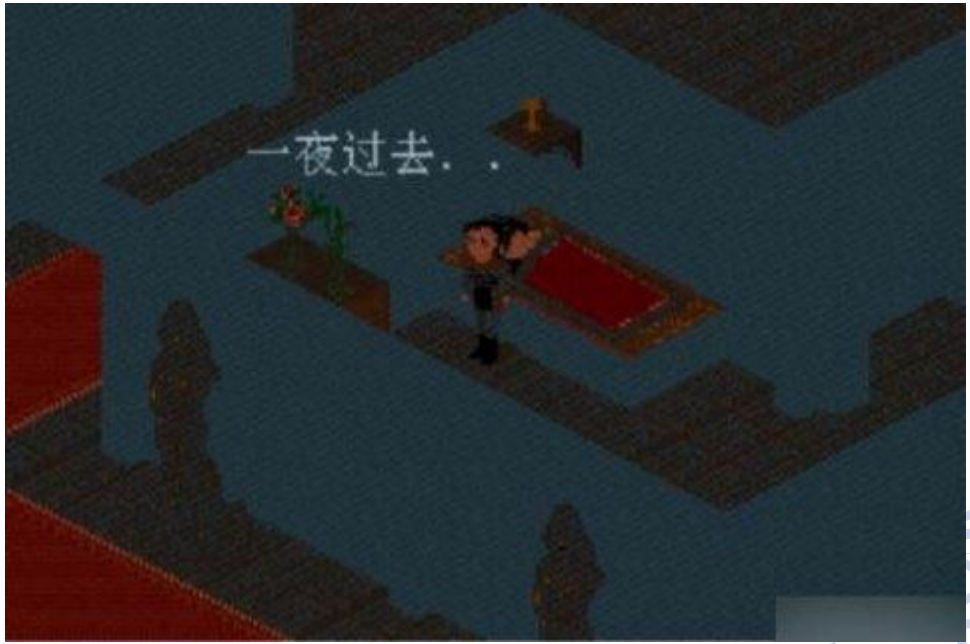

《仙剑奇侠传1》

PingCAP TiDB

~~TP~~ 处女秀

- 我们：用的咋样？
- 客户：同步数据之后做实时分析真的挺方便的...
- 我们：...

中台 AP 能力 - Syncer

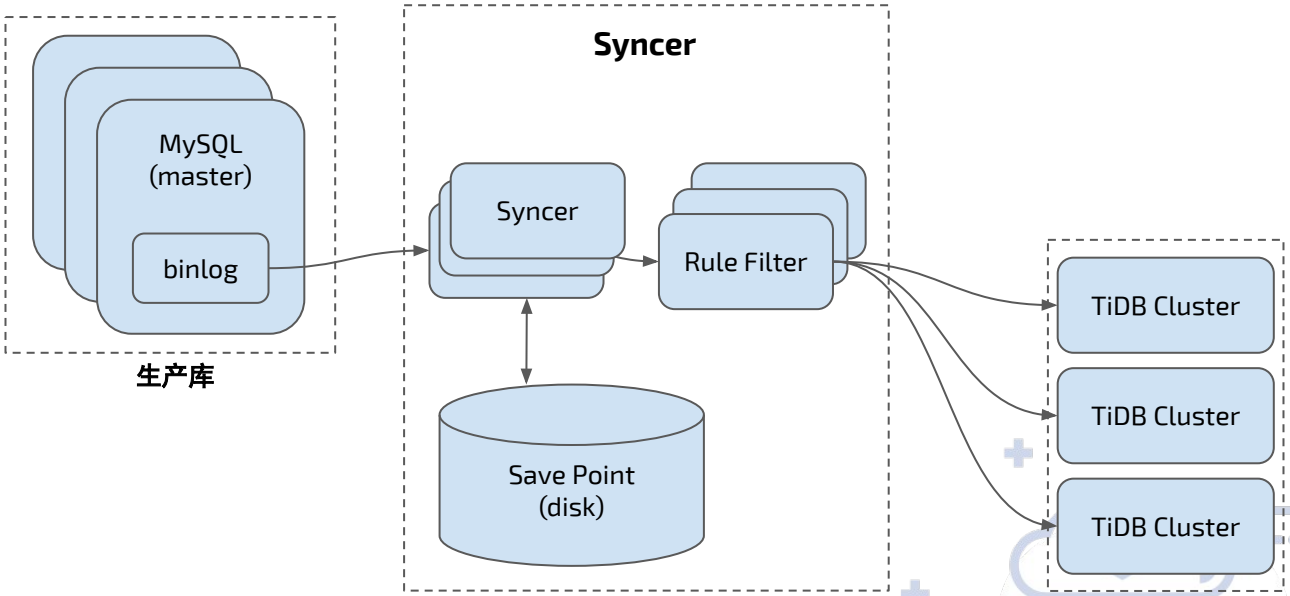

中台 AP 能力 - Coprocessor

```
SELECT COUNT(*) FROM t WHERE pk > 10 AND c2 = 'foo';
```

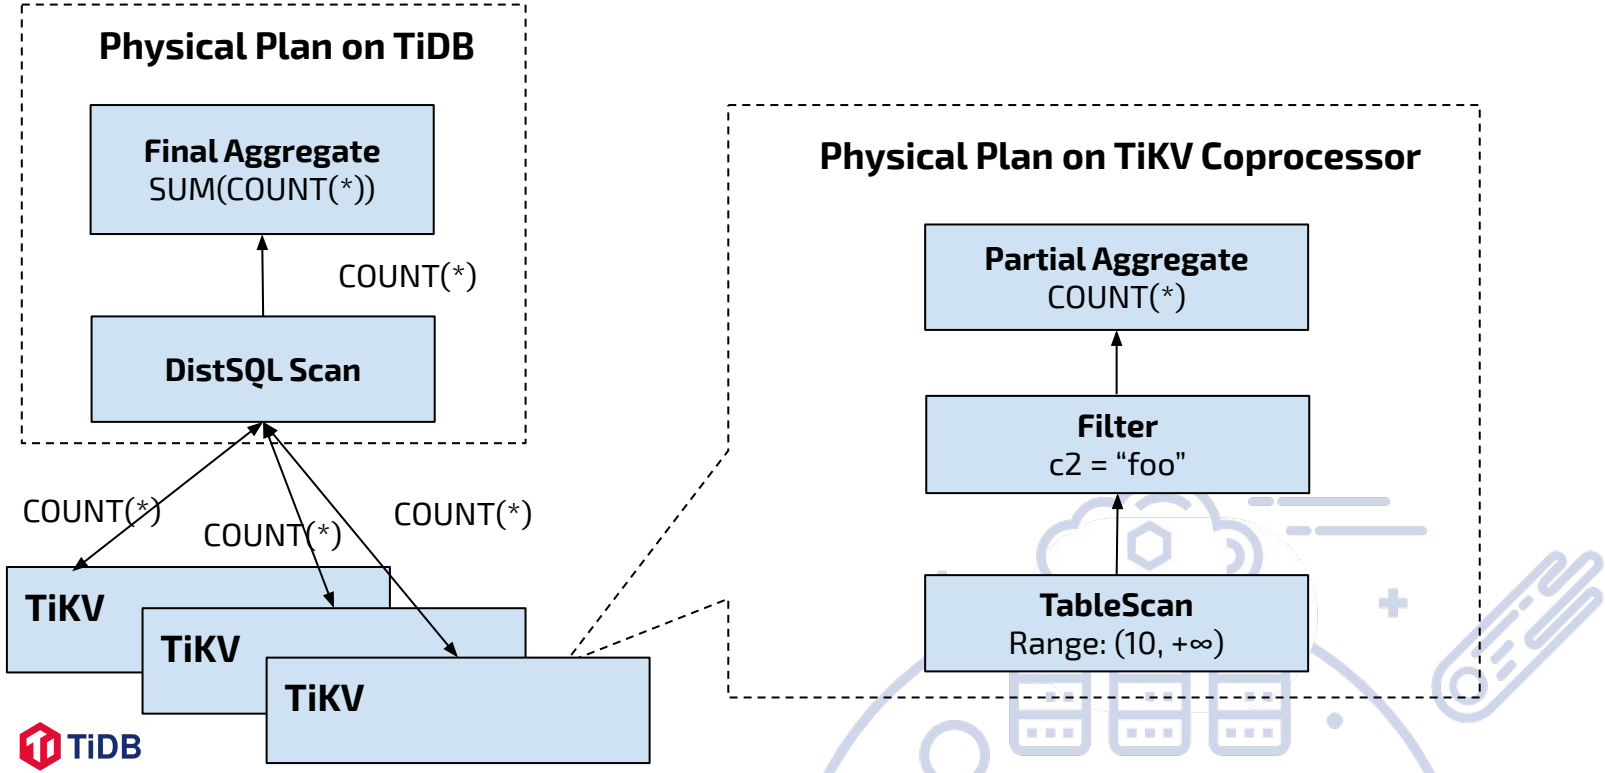

PingCAP TiDB

中台 AP 能力

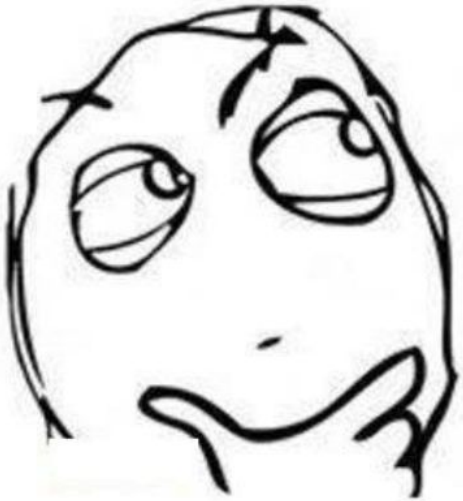

- TiDB 非常适合中台场景
- 协议兼容，轻松同步 MySQL 生产库
- 透明无障碍的跨分片查询
- 数据实时落地
- 海量存储允许多数据源汇聚
- 备库 - 中台分析二合一

Everyone Happy Now?

PingCAP TiDB

一年以后

- TP 场景
  - 客户：虽然还有各种问题...真香！
- AP 场景
  - 客户1：年度报表算的好慢！
  - 客户2：老是 OOM！
  - 客户3：没法和大数据平台结合！

不匹配的算力

https://tinyheadedkingdom.com/

PingCAP TiDB

不匹配的算力

- TiDB 之间无法直接交换数据
- TiKV 之间也无法在计算过程中交换数据
- 海量存储（TiKV），半单机计算（TiDB）
    - 只能通过 TiDB 服务器 Scale-Up 改善
- Coprocessor 无法处理需要数据交换的算子
    - Join，Full Aggregation，Distinct

抉择

- 要么将 TiDB 或 TiKV 串起来
  - 完全重构优化器和执行器，打造 MPP Engine
  - 风险大，时间长
- 要么，借助外力，拥抱生态
  - 需要一个开源分布式计算框架
  - 成熟度高，用户群广泛

借助外力 - TiSpark

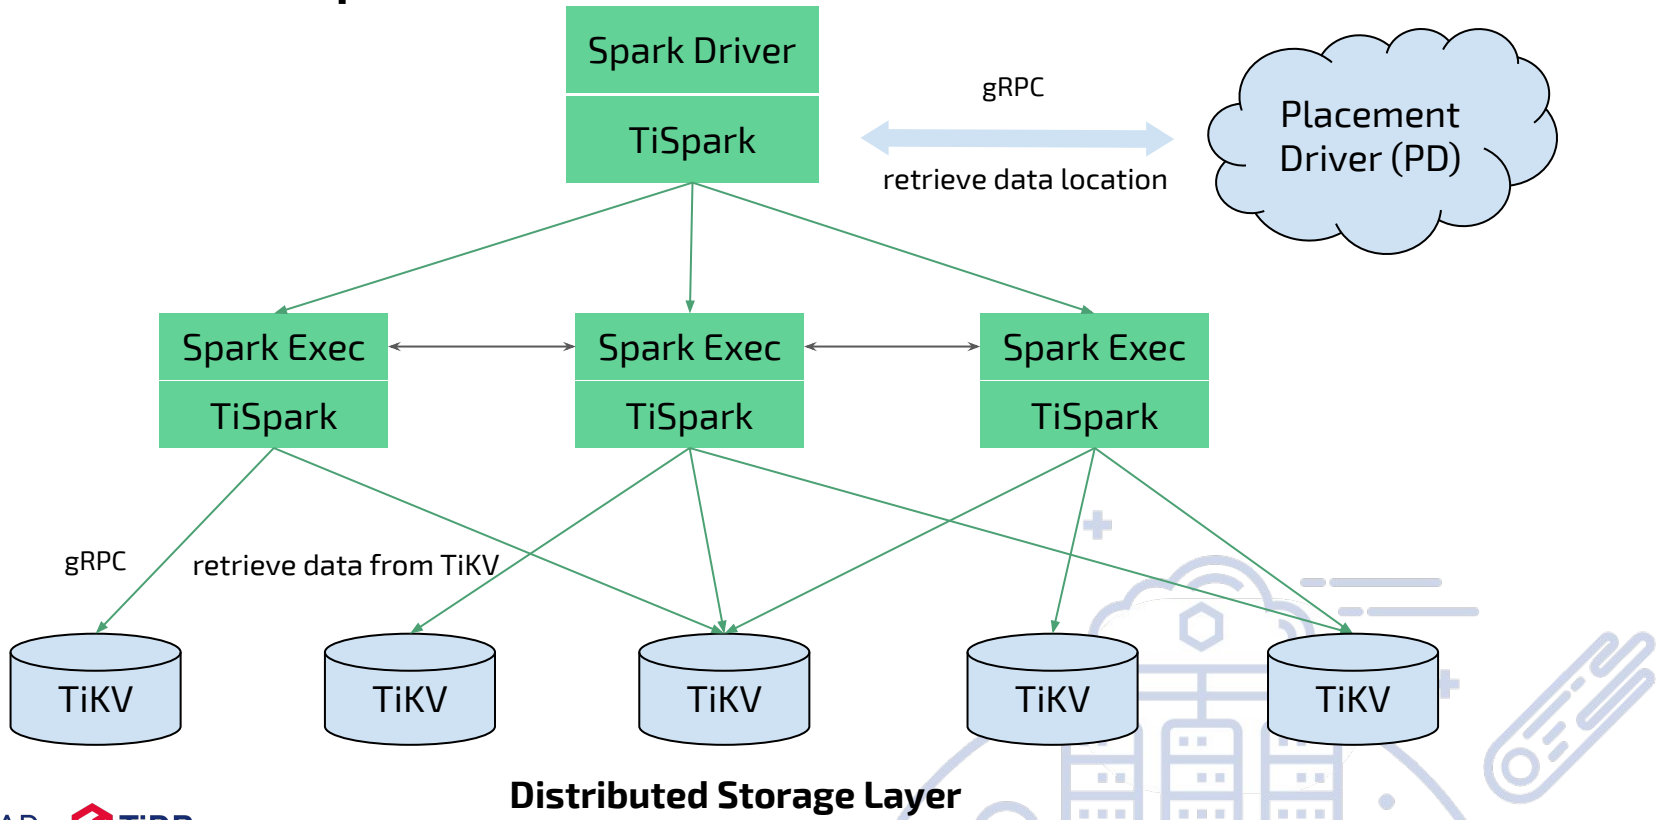

PingCAP TiDB

TiSpark

- Spark 帮我们做分布式计算
  - 成熟的分布式计算平台
  - 更快（？），更多，更稳（？）
- 完整继承 Apache Spark 生态圈
  - 无痛衔接大数据生态圈
  - 脚本，JDBC，Python，R，Apache Zeppelin，衔接 Hadoop 数仓...

TiSpark - 易果生鲜

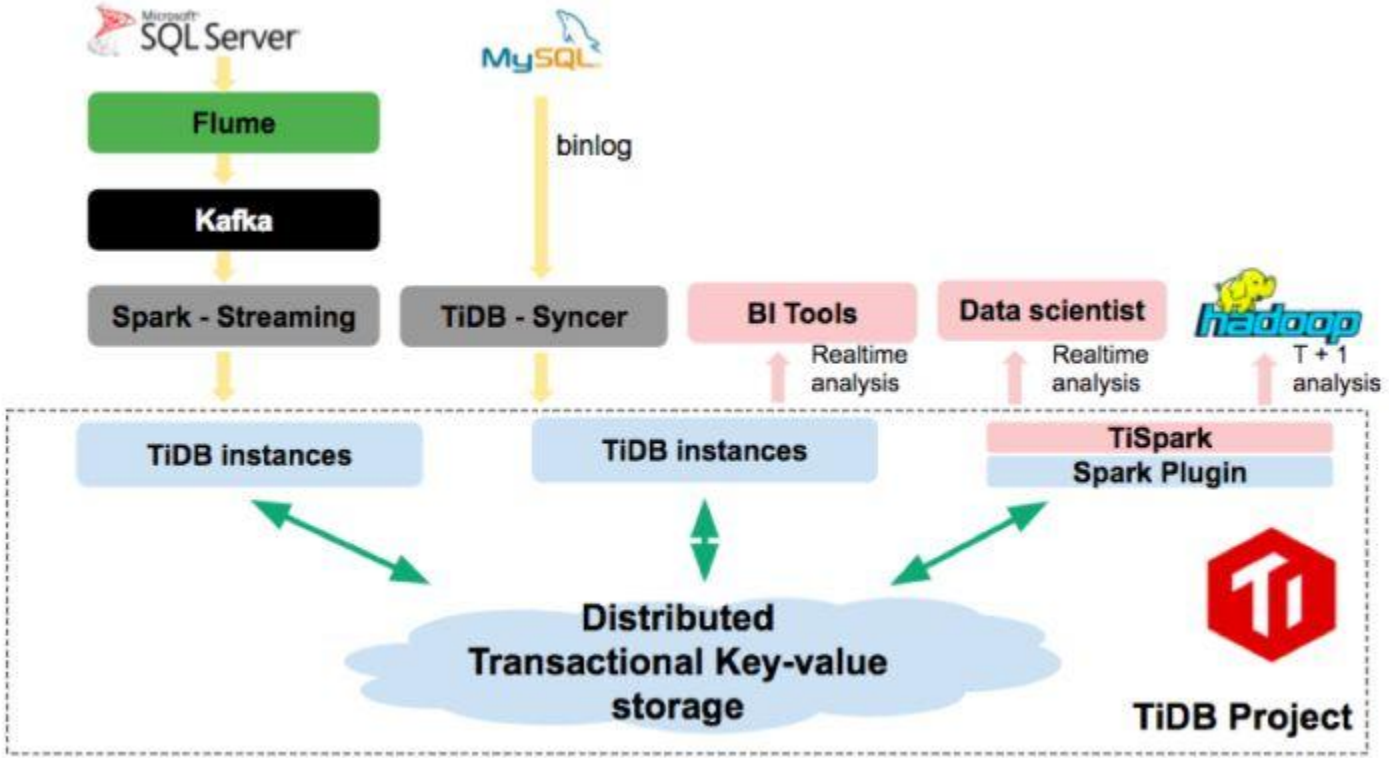

Everyone Happy Now?

PingCAP TiDB

TiSpark

- Apache Spark 只能提供低并发的粗暴计算
  - 计算模型重，资源消耗高
  - 更合适报表和重量级 Adhoc 查询
- 用户在很多场合下仍需要高并发中小规模 AP 能力
  - 低消耗低延迟的复杂查询能力
  - TiDB 运维远比 Spark 集群简单


BACK
TO
START

与此同时...

- 我们也在围绕单机 TiDB 进行各种优化
  - 在中小规模场景更聪明，更高效，更迅速
- 优化器
  - 你叫它优化器？ → RBO + CBO 优化器 → Cascades 优化器（WIP）
- 执行器
  - 经典火山模型 → ~~JIT~~ Batch Execution → Vectorized Execution（WIP）
  - 更好的并发与 Pipeline
- 分区表，Index Merge 等等

TiDB 1.0 vs 2.0

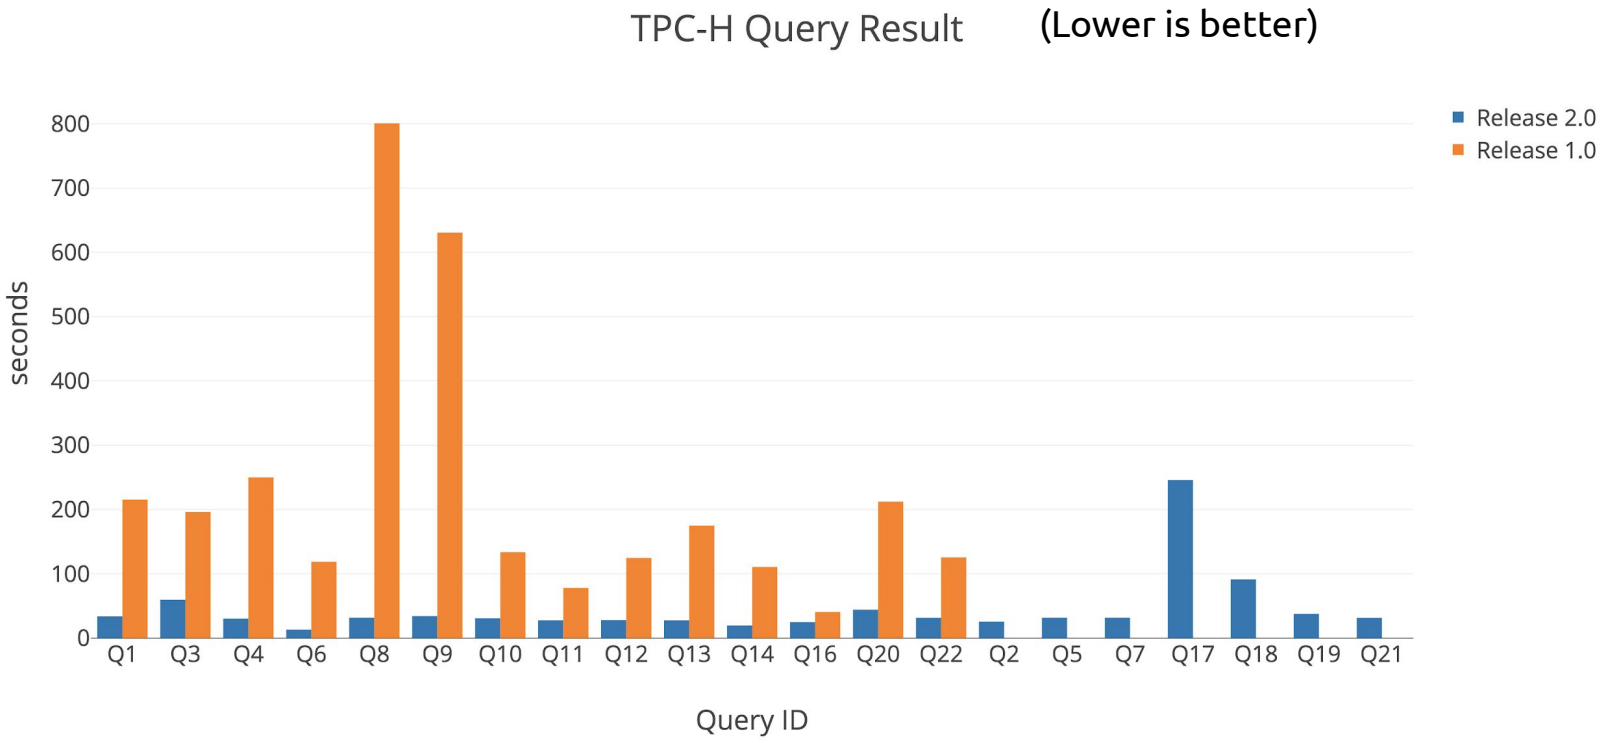

PingCAP TiDB

TiDB 2.0 vs 2.1

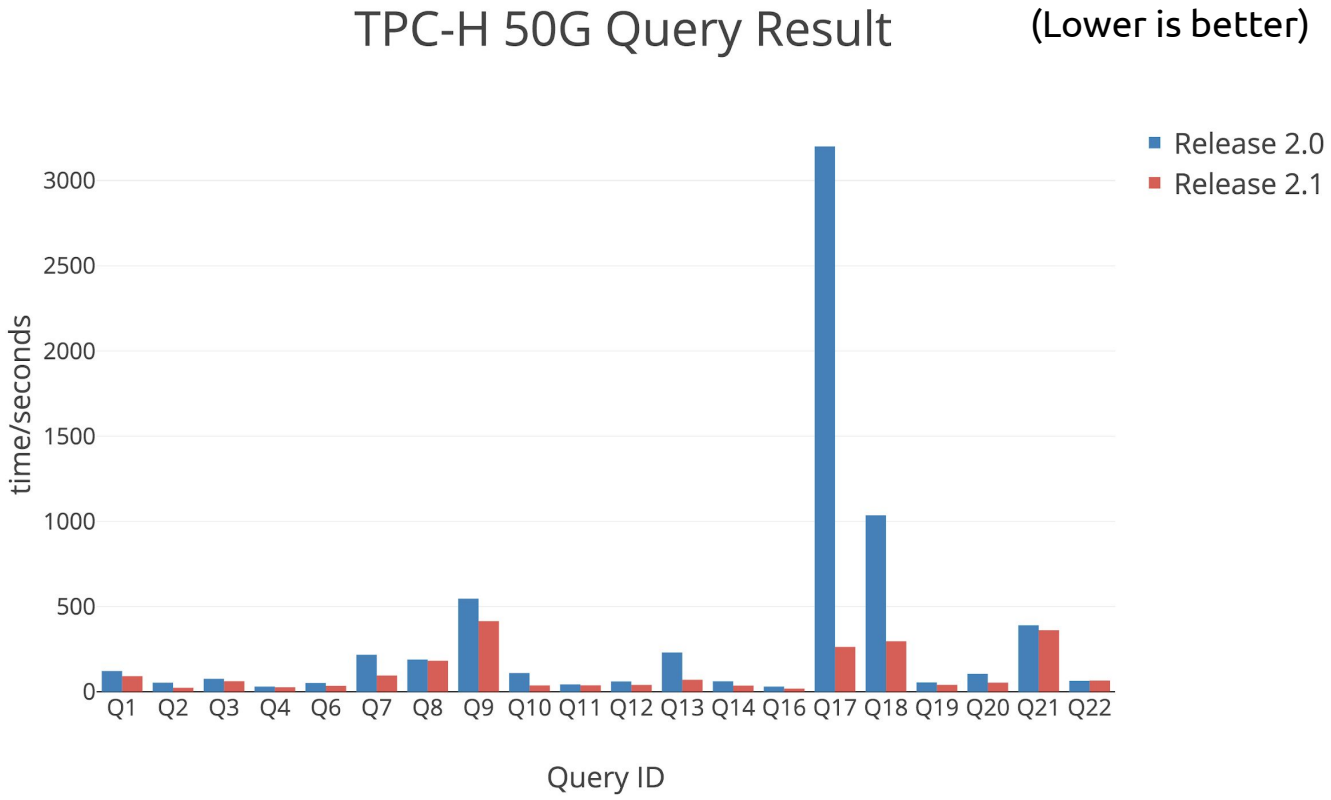

PingCAP

Everyone Happy Now?

PingCAP TiDB

核心矛盾

- 至此，我们仍然有 2 个核心矛盾：
  - 行存对于分析场景不友好
    - 『没有列存，你们也敢说自己是 HTAP？』
  - 无法做到 Workload 隔离
    - 『我跑跑查询 CPU 就 1000% 辣！』
    - TiSpark 场景下会更糟糕

行存 vs 列存

行存

id	name	age
0962	Jane	30
7658	John	45
3589	Jim	20
5523	Susan	52

SELECT avg(age) from emp;

列存

id
0962
7658
3589
5523

name
Jane
John
Jim
Susan

age
30
45
20
52

TP / AP 干扰

无法兼顾？

『如果你妈和你老婆都掉进河里，你要救哪个？』

『为什么不能都救？』

TiFlash Extension - 2019年

- 通过 Raft Learner 独立同步一套列存
  - Raft Learner 提供极低消耗的副本同步
  - Raft Learner 读取协议配合 MVCC 提供**强一致**的读取
- 通过 Label 进行物理隔离
  - AP / TP 作业互相无影响
- 部分基于 ClickHouse

TiFlash 架构

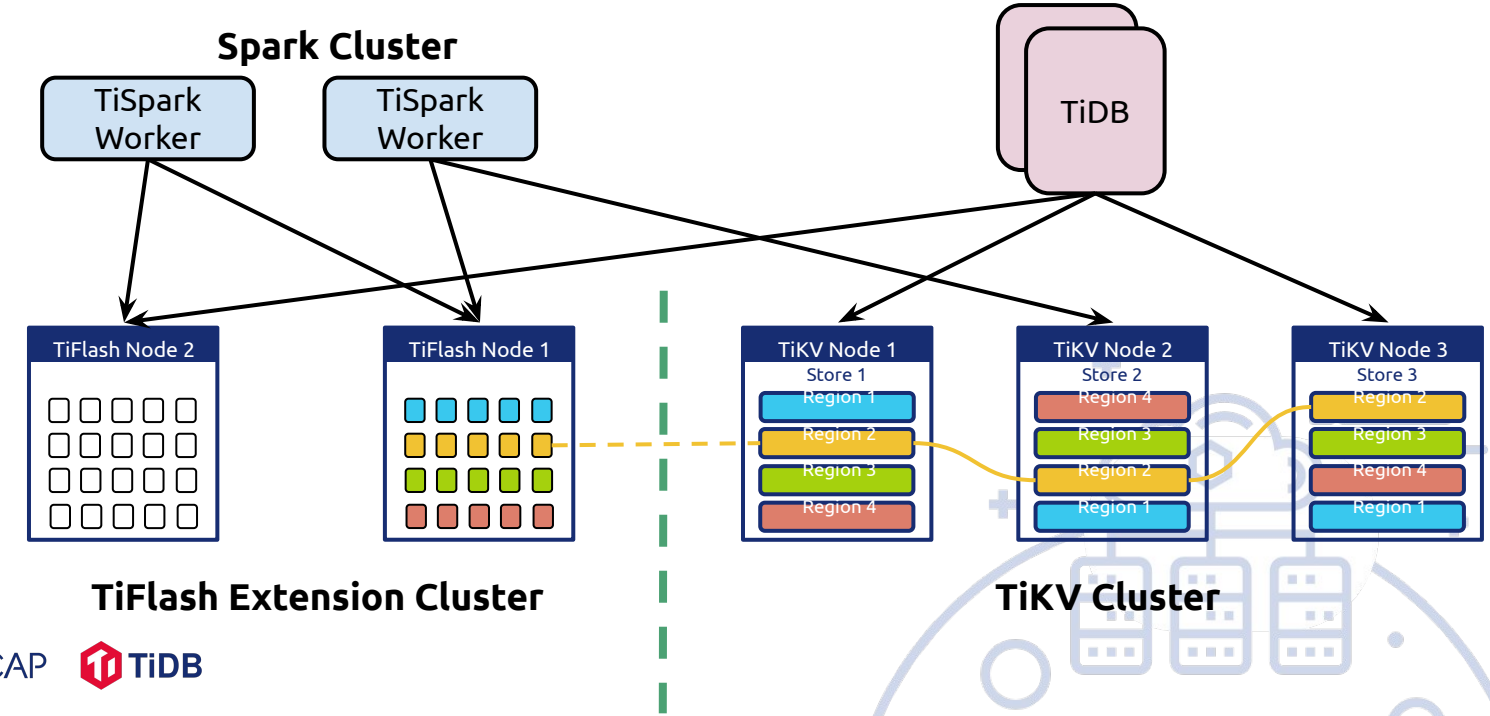

PingCAP TiDB

Raft Learner - Sync

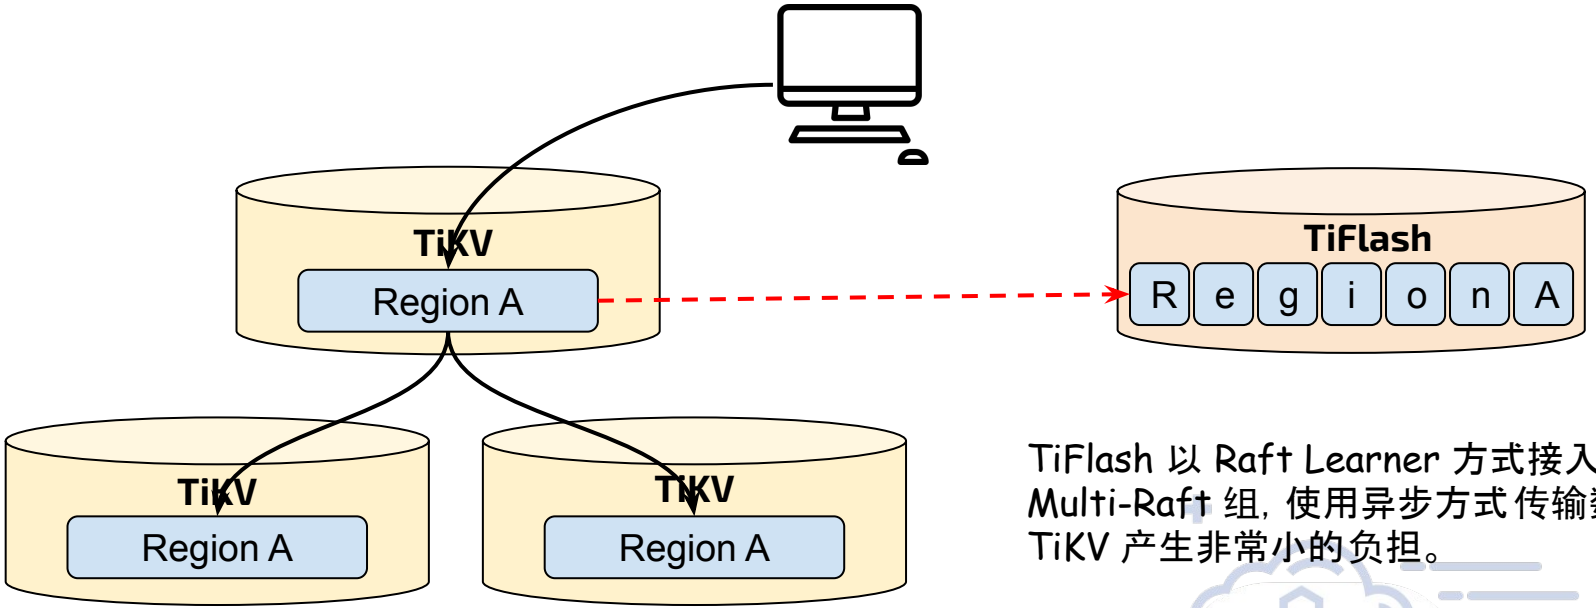

TiFlash 以 Raft Learner 方式接入 Multi-Raft 组，使用异步方式传输数据，对 TiKV 产生非常小的负担。

当数据同步到 TiFlash 时，会被从行格式拆解为列格式。

Raft Learner - Read

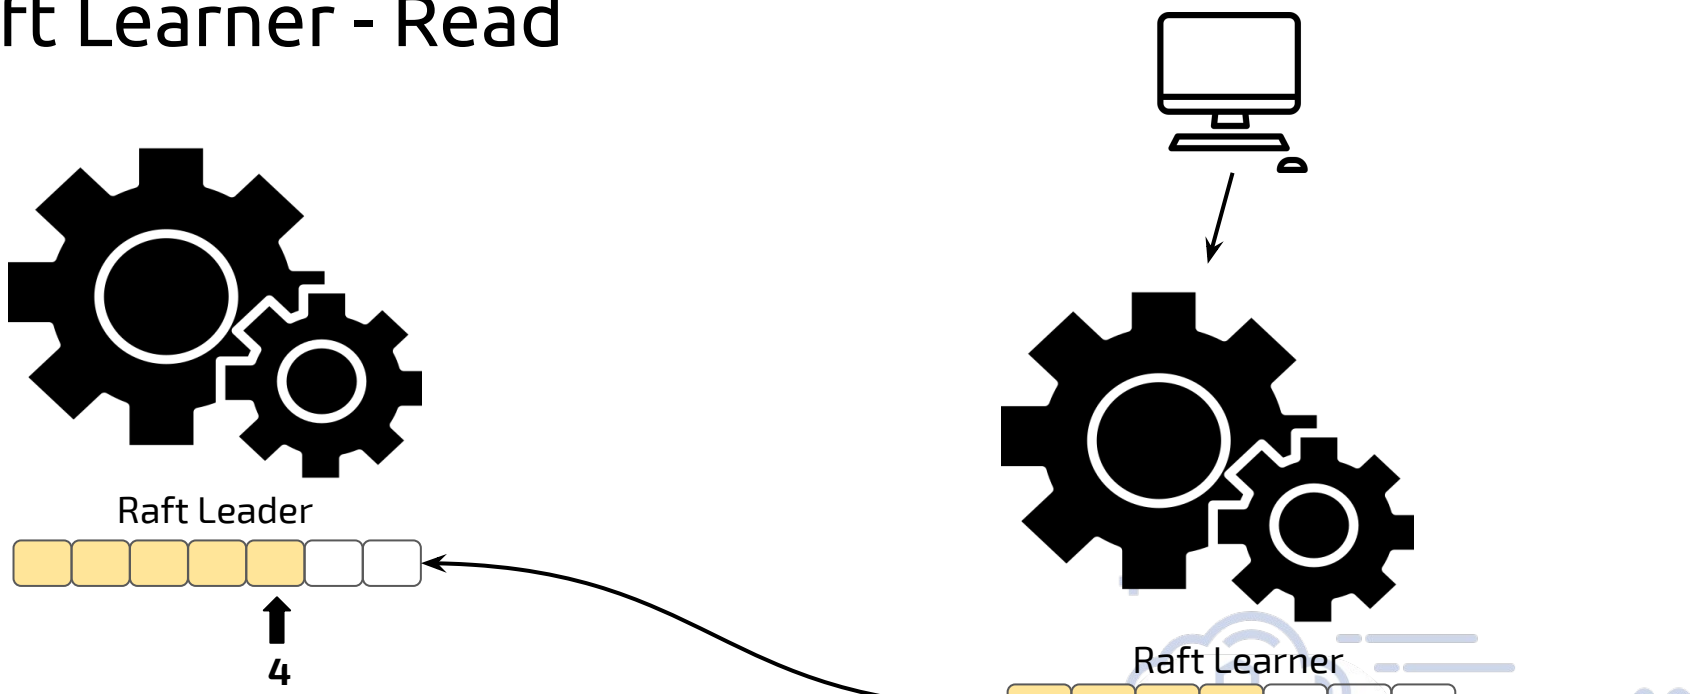

当读取数据时，TiFlash 发送 Raft 索引校对请求。

Raft Learner - Read

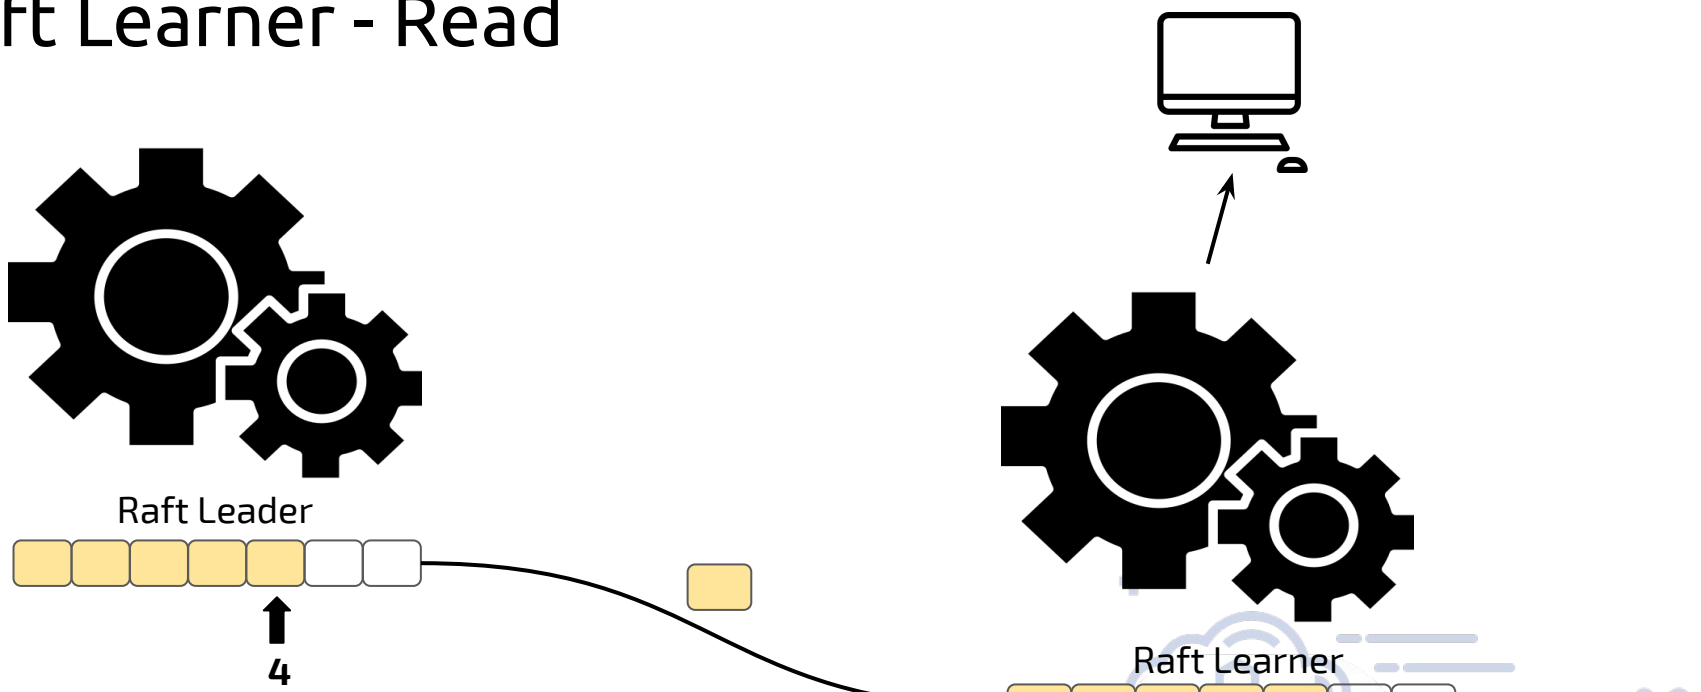

当数据同步到读取请求发送时间点的进度时，TiFlash 才提供读取。

隔离

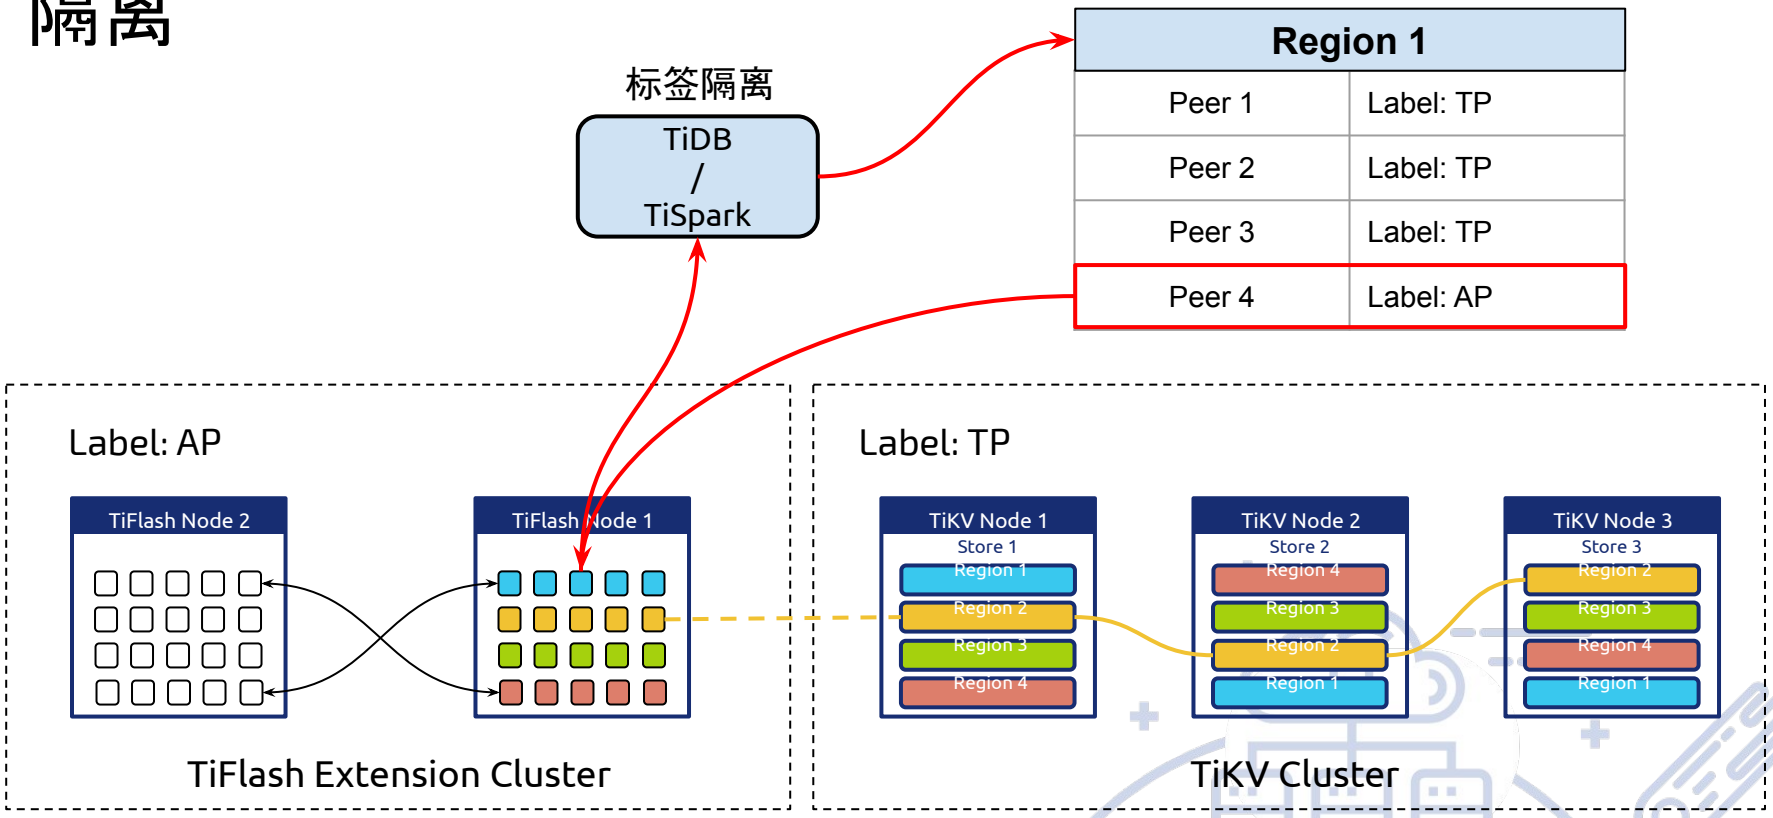
标签隔离
TiDB
/
TiSpark
Region 1
Peer 1
Label: TP
Peer 2
Label: TP
Peer 3
Label: TP
Peer 4
Label: AP
Label: AP
TiFlash Node 2
TiFlash Node 1
TiFlash Extension Cluster
Label: TP
TiKV Node 1
Store 1
Region 1
Region 2
Region 3
Region 4
TiKV Node 2
Store 2
Region 4
Region 3
Region 2
Region 1
TiKV Node 3
Store 3
Region 2
Region 3
Region 4
Region 1
TiKV Cluster

融合

```
SELECT AVG(s.price) FROM prod p, sales s
WHERE p.pid = s.pid
AND p.batch_id = 'B1328';
```

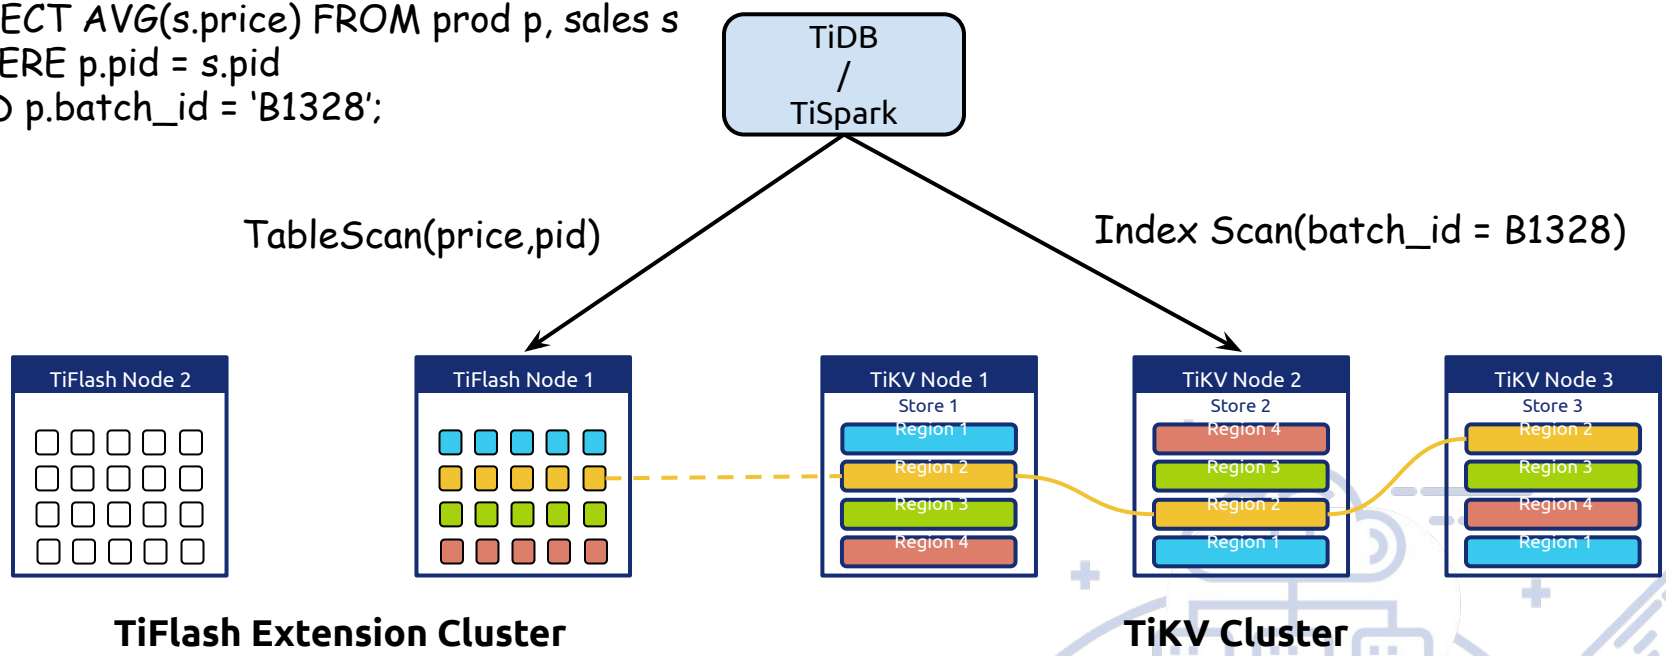

性能

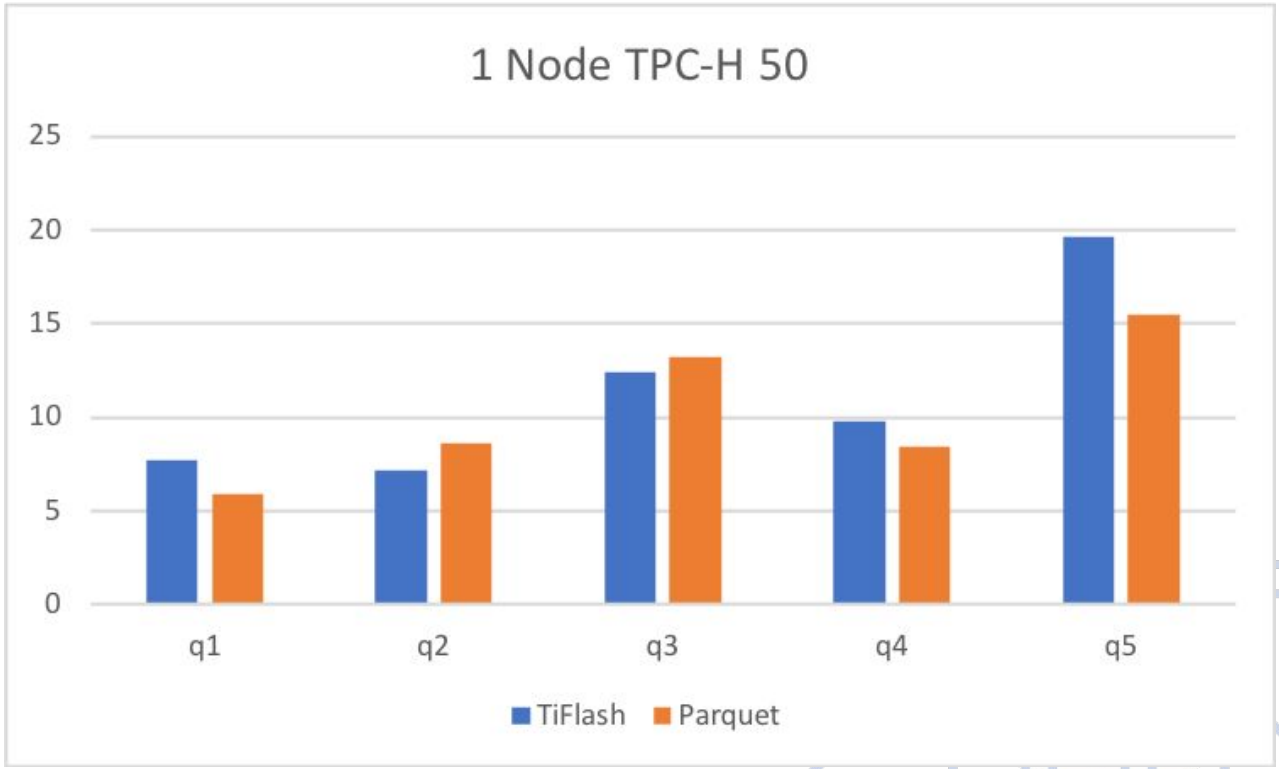

TiFlash 项目状态

- Ready for POC now
  - Spark 入口
- 2019年内 GA
  - 包含 TiSpark 以及 TiDB 双入口

至此为止

- TiDB = ~~X% TP + Y% AP~~ = HTAP
  - TiDB 并不需要你选择 TP 还是 AP，它就是 HTAP
- 一套平台，兼容行存列存
  - 无痛数据同步
- 当主 TiDB 集群承担 TP 服务时，方便地在列存上进行分析
- 或者，将列存当做索引，和行存共同提供混合服务

TiDB Today

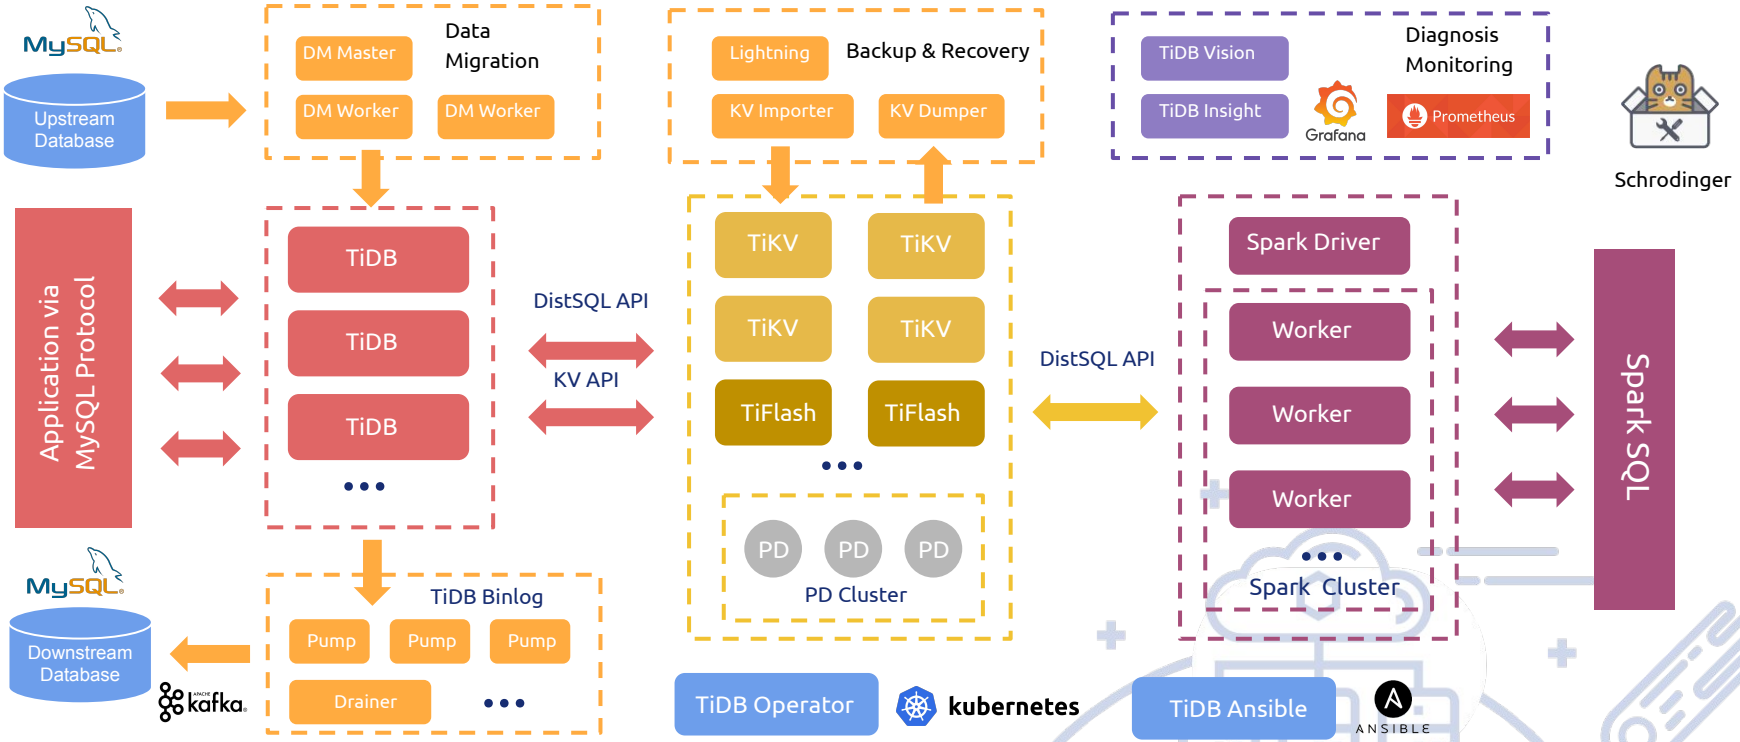

PingCAP TiDB

Everyone Happy Now?

PingCAP TiDB

我们还缺什么

- TiSpark 作为唯一分布式计算引擎
  - 缺少中规模快速查询的解决方案
  - 略重的模型(MR 模型)- 仍需要 MPP 引擎
- 写入需要通过 TiKV
  - 大批量写入速度吞吐不够
  - 副本必须先以行存方式写入再同步为列存

MPP 引擎 - Step 1

让 TiFlash 节点之间可以交换数据，
组成 MPP 集群。

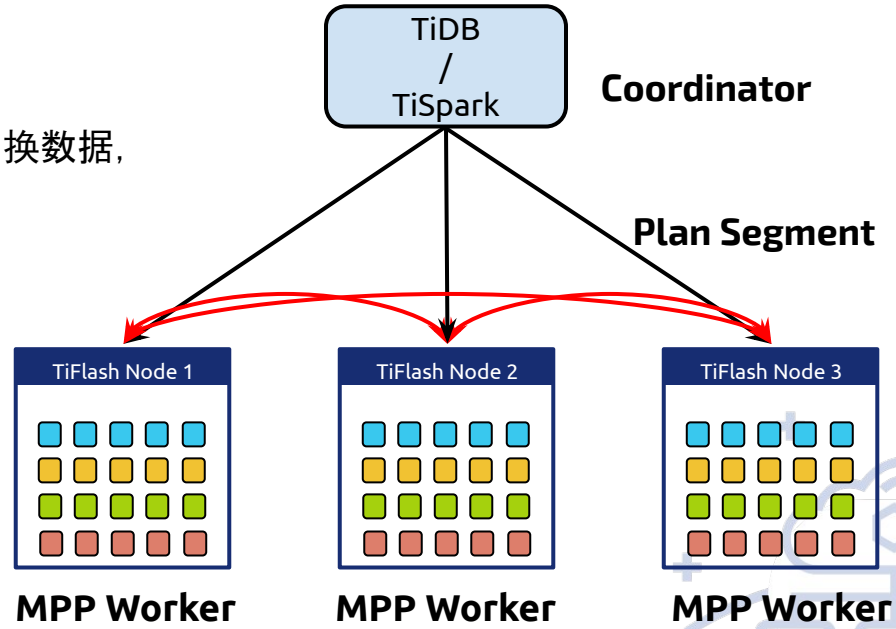

MPP 引擎 - Step 2

统一协处理器层，让 TiKV 和 TiFlash 都能组成 MPP 集群。同一套代码，同一套引擎。

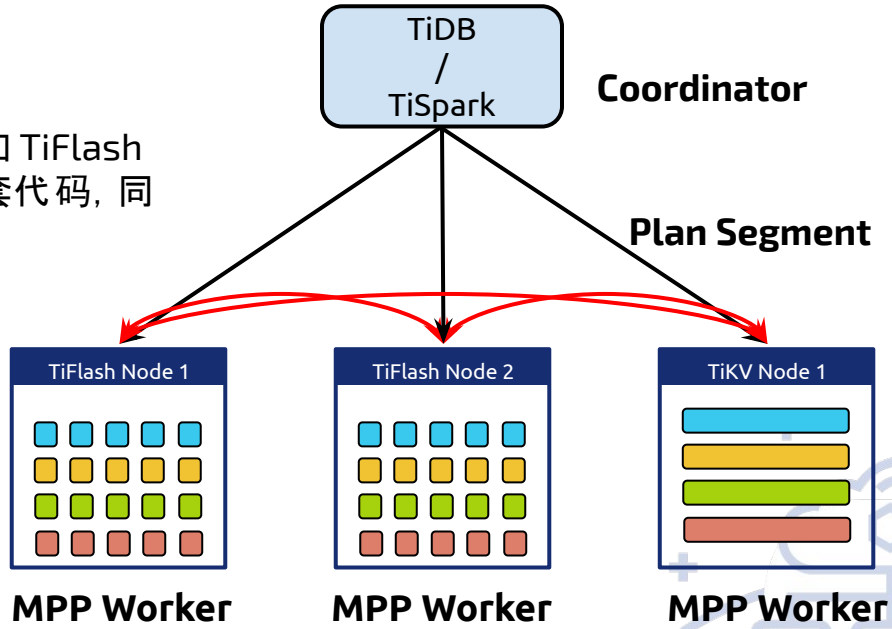

写入加强

- TiSpark 批量写入
  - 直接写入 TiKV（WIP，2019 五月内）
    - TiSpark 终于不是只读系统了
  - 直接写入 TiFlash
    - TiFlash 需要能承担 Raft Leader 角色
    - TiFlash 侧完整的 Multi-Raft 协议对接

其他

- 可拔插的存储引擎，除了行存列存之外
- Follower + Learner Read，配合标签隔离：更精细的分层 Workload 分担
- 预计算类优化
- 更优化的存储模型
- 更大的集群规模
- 以及等等：还有很多其他工作...

Everyone Happy Then?

努力思考，努力改进，然后？

We will see.

PingCAP TiDB

PingCAP

Thank You !